基本信息

- 名字 吴雨羲
- 专业: 华南师范大学 （网络工程）
- GitHub: https://github.com/631068264
- 个人主页: https://631068264.github.io/
- Gmail: 631068264@qq.com
- 手机: 18320011822

个人专长

- 熟悉AIGC相关开发，在LLMs(ChatGLM，Baichun，Qwen，Llama, 等)进行微调和RAG， Stable Diffusion 微调Lora ，使用 Langchain, Transformers, PyTorch, 向量数据库等。
- 熟悉云原生(k8s)相关，使用过k8s，rancher，rke，k3s，kubeflow，istio，prothmeus等，曾经为 autok3s，karmada，kubeflow(fairing 组件)等大型开源仓库贡献代码，了解ebpf，openEBS等CIS组件，calico等CNI组件
- 了解TensorFlow，Pytorch，sklearn，pandas，numpy以及机器学习的基础知识。
- 熟悉Python and Golang后台开发，了解Spark，ClickHouse, Elasticsearch，NoSQL , Kafka等

工作经历

广州致景信息科技有限公司

2024年6月至现在

模型部署工程师

主要从事算法工程：聚焦**模型推理加速、推理流程优化与集群算力调度**。从模型加载、前处理、推理执行到后处理的全链路性能优化，从0到1构建多个算法服务SDK与可观测性体系，持续推动服务稳定性、资源利用率和研发效能提升。具备技术选型、方案设计到跨团队落地的完整推动能力。

- 模型推理加速
    - 负责Triton server推理服务的技术选型与落地，牵头制定小模型优化方案：通过CUDA/System Shared Memory池、异步推理和前后处理并发降低单请求开销，支撑小模型服务的高并发推理。在具体小模型服务压测中，QPS从不足三提升至几百+；并支持按应用和模型依赖进行独立加载、卸载与资源管理，减少重复部署和维护成本。
    - 针对自研的生图模型推理流程，包括不限于下面手段
        - 引入cache与compile等优化UNet forward过程，缩短40%推理时间
        - 利用CuPy将部分CPU密集型矩阵运算迁移至GPU，图片上传下载优化
        - 使用shm+lrucache解决lora和底膜切换耗时和多pod加载的偶发性bug
- 系统架构与SDK研发

    - 架构设计并推动Triton标准化服务框架落地，算法侧仅需实现业务编排与前后处理即可上线；制定加解密、共享内存、Span追踪等规范，支撑多场景灵活组装部署。
    - 主导 deploy-sdk与 MCP Server SDK研发：统一封装调度对接、任务拉取、模型解密加载、心跳保活等能力；定制N8N断点重试机制，通过Redis状态协调与分布式锁，系统性解决MCP长连接偶发断连丢结果问题，推动跨团队（算法/平台/前端）联调落地。
    - 完成 SSE Server SDK研发，封装三类异步任务处理模式，打通前端与算法服务的标准化交互通道。
    - 制定skill编写规范给团队使用
    - 改造lark-openapi-mcp成多租户，并且可以运行在容器里面，提交过一些修改PR
    - 改造原有模型加解密方案结合k8s特性，将大模型的解密速度从原来20秒，缩短到3秒。
- 资源调度与可观测性
    - 牵头自动扩缩容方案调研与选型，基于KEDA设计自动扩缩容方案，配合deploy-sdk优雅退出与任务重调度，避免低峰期GPU资源浪费。结合GPU共享策略，最大化GPU利用率。
    - 设计模型性能测试方案，通过DCGM+Prometheus采集GPU指标并输出性能报告，指导机型选型与部署策略。
    - 从0搭建统一可观测性组件zj_obs并推广至全团队：整合日志、链路追踪与SLS结构化上报，建立告警分类与分级通知机制，目前已成为所有SDK的标配基础设施。

联通（广东）产业互联网有限公司

2021年10月至2024年5月

软件开发工程师 (AIGC and 云原生)

- AIGC方面
    - 使用Python给医院开发医疗导诊AI系统（LLMs + RAG ），基于院内介绍和科普知识，为病人多轮导诊问答服务，为数字人视频生成科普文章材料，等功能。
    - 使用Python开发问答系统（LLMs + RAG ），基于公司材料文档，支持不同文件格式(ppt, pdf, word, txt, json, 等)。
    - 开发ChatBI项目：分析数据，生产SQL，分析数据库，生成报表等
    - 不断优化RAG质量（数据清洗，优化索引，问题的扩写、改写、意图分析，多路召回，重排，prompt优化等）。使用 langchain , transformers , pytorch等。
    - 通过模型分布式多卡微调去完成对应任务（参数优化，分布式训练，提高准确率等）例如：低代码平台信息抽取，医疗知识大模型等
    - 使用过vLLM等大模型推理加速框架
- 云原生
    - 预研云原生组件（Istio, Karmada, Velero, Rancher, K3s, Prometheus等），使用golang开发云边协同平台
    - 开发agent实现自动跨闸机管理集群（k3s，k8s），补充rancher的云边协同能力。
    - 使用原生k8s api+ prothmeus 开发容器云监控平台 ，自动化生产helm chart，监控k8s workload资源指标，应用指标等。
    - 基于kubeflow+valcano开发机器学习平台，让AI模型的GPU集群进行推理和训练，并且利用istio filter统计AI模型调用情况。
    - 开发k8s operator部署协同平台
    - 集群或pod的备份还原
- 除了具体的开发工作，我还在项目中承担了项目管理的角色，负责项目的计划、进度控制和团队协调等工作。我具备良好的沟通能力和团队合作精神，能够高效地组织团队完成项目任务。

一知安全科技有限公司

2019年5月至2021年10月

后台开发（Python Golang）

- 将之前只有一个的臃肿后台系统进行拆分重构，使用 python重写 web api 接口，使用 golang 重构内部服务，根据业务分别拆分成探针、客户端服务端，流量处理、定时任务 4 个微服务。模块之间使用 grpc 通信，并且 docker 化，使用 docker-compose进行管理。项目主要用到 kafka，mysql，clickhouse，elasticsearch，logstash 等组件。在服务之间使用了速率限制和断路器。
- 在后端开发和组件服务的性能优化方面有经验.。平台核心系统功能包括分析客户镜像流量、生成警报和攻击追踪。
- 针对之前部署慢，模块间包版本冲突等的问题，使用docker化和Jenkins、CI打包、减少镜像体积等。把部署过程规范起来，节省部署成本，简化安装升级过程，让客户可以自主完成。
- 由于数据量大（千万，亿左右），原展示数据都是放在mysql,clickhouse，客户基本都是单机。遇到查询慢，消耗资源多，数据结构多变等问题。引入ES，数据分级、增量聚合，减少无用数据保存，优化部分原有查询语句，削减定时统计改成增量缓存，降低消耗资源。系统查询timeout或者崩溃概率减少更加稳定。

广州美聚网络科技有限公司

2017年2月至2019年4月

数据分析 (数字货币交易 Python开发)

- 建立分布式爬虫获取国内外大约19家交易所共计130多个币种实时和历史K线，深度和交易记录和统计。包含数据采集和清洗使用Python开发，主要用到numpy,pandas等库。
- 建立实时的量化系统，分析采集到的数据，通个各种交易指标和交易策略分析买卖点，每个币种有11种K线周期，每个周期对应6种常用的指标配上不同各种参数+约20种交易策略（针对2种周期），进行计算。主要用到numpy,pandas，tailib等库。
- 根据分析到的数据买卖点特征值进行量化分析，利用机器学习拟合预测计算收益。主要用到TensorFlow。
- 利用supervisor+Fabric+slack监控进程，服务器CPU/内存，提醒和重启服务。自动化多机器部署，重启脚本。

实习经验

珠海布卡科技有限公司

2016年5月到2016年11月

后台开发工程师（Python）

- 优化logstash处理日志脚本,完善日志收集工作，编写根据配置和日期动态建表、加字段，自动生成对应的logstash配置的Python脚本。
- 使用Django编写漫画管理系统。（包含AWS S3的对接接口，图片的处理）

广州优将人力资源有限公司

2015年7月到2016年3月

后台开发 (Java , Python 后台开发 , 安卓等)

- 前2个月主要进行Java后台开发（APP、微信），还来因开发进度需要使用Python重写Java后台，用时1个月。
- 负责编写一个内部管理系统的WebApp（包括后台和前端）。
- 后来由于人手原因接手Android开发，学生端和客户端各做了大概4个迭代。

证书

Certified Kubernetes Administrator （CKA）